

Robôs Quadrúpedes na Coleta de Dados Fenotípicos em Plantações de Soja: Revolucionando a Pesquisa Genética

¹Heinz Felipe Cavalcante Rahmig, ²Nabila de Paula e Silva, ³Lucas Araújo Pereira, ⁴Alexandre Costa Ferro Filho, ⁵Andre Felipe dos Santos Caraiba, ⁶Andre Luis Araujo de Souza, ⁷Carlos Eduardo Rocha Sousa, ⁸Danielle Soares Leite Alfredo, ⁹Gustavo Ribeiro Moura, ¹⁰João Pedro Aguiar Formiga Matos, ¹¹João Vitor Costa, ¹²Pedro Antônio Maciel Saraiva, ¹³Marcelo Ramos Jordão, ¹⁴Victor Matheus Silva Souza, ¹⁵Victor dos Santos Ferreira

UFG – Universidade Federal de Goiás
EMC – Escola de Engenharia Elétrica, Mecânica e de Computação,
INF - Instituto de Informática
Goiânia - GO

¹heinzfelipe@egresso.ufg.br, ²nabilaps@egresso.ufg.br, ³apereiral@ufg.br, ⁴alexandre_ferro@discente.ufg.br, ⁵andrecaraiba@discente.ufg.br, ⁶de.de@discente.ufg.br, ⁷carloosedurochasousa@gmail.com, ⁸daniellesoares@discente.ufg.br, ⁹gustavormoura@hotmail.com, ¹⁰jpagliari39@gmail.com, ¹¹joao_costa2@discente.ufg.br, ¹²pedro.saraiva@discente.ufg.br, ¹³marcelo.jordao@discente.ufg.br, ¹⁴victormatteus@discente.ufg.br, ¹⁵vitor.santos.ferreira21@gmail.com

Resumo: Este estudo explora o uso de robótica quadrúpede no sensoriamento de fazendas dedicadas ao aprimoramento genético de soja, uma estratégia crucial para enfrentar o crescimento populacional e a crescente demanda por alimentos. Com o espaço agrícola limitado, o aprimoramento genético surge como solução para desenvolver culturas mais produtivas e resistentes. Tradicionalmente, a coleta de dados fenotípicos apresenta desafios como baixa escalabilidade e susceptibilidade a erros humanos. Este projeto propõe uma plataforma robótica autônoma, equipada com LiDAR 3D, para a coleta não destrutiva e precisa de dados em plantações de soja, visando superar esses desafios. Atualmente em fase inicial, o estudo foca em testes e coleta de dados para validar a eficácia desta abordagem inovadora, com o objetivo de extrair informações fenotípicas vitais para o aprimoramento genético.

Palavras Chaves: Fenotipagem automatizada, robô quadrúpede, soja, LiDAR 3D, navegação autônoma, aprendizado por reforço.

Abstract: This study explores the use of quadruped robotics in sensing farms dedicated to the genetic improvement of soy, a critical strategy to address population growth and the increasing demand for food. With limited agricultural space, genetic improvement emerges as a solution to develop more productive and resistant crops. Traditionally, the collection of phenotypic data presents challenges such as low scalability and susceptibility to human errors. This project proposes an autonomous robotic platform, equipped with 3D LiDAR, for the non-destructive and accurate collection of data in soy plantations, aiming to overcome these challenges. Currently in its initial phase, the study focuses on testing and data collection to validate the efficacy of this innovative approach, with the goal of extracting vital phenotypic information for genetic improvement.

Keywords: Automated phenotyping, quadruped robot, soy, 3D LiDAR, autonomous navigation, reinforcement learning.

1 Introdução

Diante do iminente crescimento populacional mundial, que a ONU (1), prevê chegar a cerca de 10 bilhões em 2050, a expansão das fronteiras agrícolas se apresenta como um desafio

considerável. Na contramão do rápido crescimento populacional, a expansão da fronteira agrícola é bastante restrita. Nesse contexto de aumento da demanda populacional, limitações de terras aráveis e desafios impostos pelas mudanças climáticas, torna-se crucial o desenvolvimento de tecnologias que promovam o aumento da produtividade agrícola de forma sustentável (2). Uma das estratégias para intensificar a produção e contribuir para o avanço no melhoramento genético é a seleção de variedades de plantas com maior produtividade e resistência a doenças, adaptadas para tolerar estresses ambientais e que demandam menos recursos químicos. A identificação dessas variedades passa pela análise do fenótipo das plantas, que é moldado ao longo de seu crescimento pela interação de fatores genéticos e ambientais (3). As práticas atuais de fenotipagem enfrentam desafios para processar eficientemente as informações geradas. Tradicionalmente, a coleta de dados fenotípicos é realizada manualmente, envolvendo medições manuais e visuais das características da planta, como altura, número de vagens e resistência a estresses bióticos e abióticos. Apesar desse processo ser relativamente preciso e de baixo custo, é demorado, pouco escalável e suscetível a erros. Assim, as pesquisas nessa área têm se concentrado no desenvolvimento de tecnologias de fenotipagem automatizadas e de alto rendimento, como o uso de drones e robôs autônomos, equipados desde câmeras e sensores avançados até módulos de computação e atuação com o ambiente (4)(5). O uso de aprendizado profundo e outras tecnologias de inteligência artificial para controlar os robôs de fenotipagem é particularmente notado pela melhoria na detecção de objetos como fileiras de culturas, órgãos de plantas, solo e obstáculos em imagens (6). Nesse contexto, a medição da morfologia tridimensional das plantas assume um papel importante e, por isso, a introdução de robótica terrestre, especialmente o uso de robôs quadrúpedes equipados com câmeras e sensores, surge como uma solução promissora, oferecendo uma possibilidade de métodos escaláveis e precisos para a coleta de dados.



Fig. 1. Robô quadrúpede acoplado com sensor LiDAR usado na coleta de dados na plantação de soja.

2 Utilização de robótica quadrúpede

A adoção da robótica quadrúpede no contexto do sensoriamento em plantações de soja é fruto de uma análise técnica aprofundada, levando em consideração as necessidades operacionais e as características desafiadoras dos terrenos a serem navegados. Esta análise foi fortemente embasada por um estudo revisado por Biswal e Mohanty (2021) (7), que destacou a superioridade dos robôs quadrúpedes em termos de mobilidade e versatilidade em comparação com as alternativas sobre rodas em ambientes heterogêneos e desafiadores, característicos das plantações de soja brasileiras. Os robôs quadrúpedes apresentam vantagens significativas em relação aos robôs sobre rodas, especialmente no que tange à manobrabilidade e à capacidade de transposição de obstáculos. A independência e o grau de liberdade proporcionados pelas pernas permitem que estes robôs se movam em múltiplas direções sem necessidade de reorientar o corpo principal do robô, uma capacidade que se mostra particularmente valiosa no contexto irregular e obstaculizado das plantações.

2.1 Hardware Setup . Para a condução dos experimentos utilizamos o robô Go1 da Unitree, que é uma plataforma robótica quadrúpede avançada. Inclui motores Go1 com torque instantâneo de 23.7 N·m, sendo capaz de atingir velocidades de até 3,3 m/s.

2.2 Sensor Setup. O RS-LiDAR-16 da RoboSense (8). é um sensor de detecção e alcance de luz (LiDAR) que oferece uma solução de percepção ambiental de alta precisão para robótica móvel e mapeamento. Possui 16 canais de pares de lasers de emissão e detecção, que fornecem uma varredura 360° do ambiente, permitindo a detecção de objetos com alta precisão em diferentes condições de iluminação e climáticas. A tabela abaixo lista alguns parâmetros de configuração do RS16. O sensor foi instalado diretamente no robô quadrúpede, fazendo com que o seu centro de gravidade fique a 44 cm acima do chão e é capaz de gerar uma nuvem de pontos detalhada do ambiente, que auxilia na navegação em tempo real e na detecção de objetos no pós-processamento dos dados coletados.

| Parâmetros | Valores |
|-----------------------------------|-------------------------------|
| Canais | 16 |
| Alcance Operacional | 40cm ~ 150m |
| Campo de Visão - FoV (Horizontal) | 360° |
| Campo de Visão - FoV (Vertical) | ±15.0° (30°no total) |
| Resolução Angular (Vertical) | 2° |
| Resolução Angular (Horizontal) | 0.1°(5Hz) ~ 0.4°(20Hz) |
| Taxa de Rotação | 300/600/1200 rpm (5/10/20 Hz) |

Fig. 2. Robô quadrúpede acoplado com sensor LiDAR usado na coleta de dados na plantação de soja.

| Estágio vegetativo | Estágio Reprodutivo |
|-------------------------|---|
| VE - Emergência | R1 - Início Florescimento |
| VC - Cotilédones | R2 - Pleno florescimento |
| V1 - Primeiro nó maduro | R3 - Início formação vagens |
| V2 - Segundo nó maduro | R4 - Plena formação vagens |
| V3 - Terceiro nó maduro | R5 - Início enchimento dos grãos R5.1: 10% R5.2: 11% ~ 25% R5.3: 26% ~ 50% R5.4: 51% ~ 75% R5.5: > 76% de enchimento |
| (...) | R6 - Pleno enchimento dos grãos |
| (...) | R7 - Início maturação |

Fig. 3. Descrição dos estágios vegetativos e reprodutivos da soja. Fonte: (9)

Metodologia

3.1 Estágios de desenvolvimento da soja. O ciclo da soja em dias pode variar entre 100 a 160 dias, dependendo da cultivar. Sua fenologia é detalhada através da categorização de seus estágios de desenvolvimento, essenciais para entender suas demandas ao longo do ciclo de crescimento. Segundo a classificação de Fehr Caviness (1977) (9), esses estágios são divididos em vegetativos (V), caracterizada pelo desenvolvimento das folhas, e reprodutivos (R), que começam com a floração, formação de vagens, enchimento de grãos, e a maturidade.

| Data Coleta | Dias após sementeira |
|-------------|----------------------|
| 20/11/2023 | 13 |
| 14/12/2023 | 37 |
| 22/01/2024 | 76 |
| 19/02/2024 | 104 |
| 12/03/2024 | 126 |

Fig. 4. Datas das coletas de dados na plantação.



Fig. 5. : Local da coleta de dados na Embrapa Arroz e Feijão. Foto tirada na última visita feita.

3.2 Coleta de Dados. Considerando que diferentes estágios de crescimento da soja podem fornecer diferentes informações fenotípicas. Usando o sensor LiDAR para mapeamento das plantas, foram feitas 5 coletas de dados no campo, com uma média de 28 dias de diferença entre cada uma e um ciclo de 130 dias. Nos estágios que vão do R4 até o R8 é possível coletar informações consistentes sobre a altura das plantas devido a maturidade da planta, e por isso estes foram os escolhidos para a avaliação. A partir de várias coletas dentro desse espaço de tempo, será possível traçar importantes insights sobre a taxa de crescimento das plantas, podendo então gerar uma estimativa da produção. A atividade de quantificar o número de plantas por metro linear mostra-se mais eficaz durante as fases iniciais do crescimento da planta. Este é o período ideal após as plantas terem se estabelecido firmemente no solo, minimizando o risco de falhas no desenvolvimento, e antes que comecem a crescer excessivamente e se misturam umas nas outras, dificultando a identificação individual de cada planta. Portanto, coletas entre os estágios V2 até R1 são os mais indicados para essa tarefa. Considerando que no final do estágio de reprodução R8, as plantas estão desfolhadas, é possível fazer uma comparação entre o número inicial de plantas coletado durante os primeiros estágios e a quantidade final de plantas no fim do ciclo, fornecendo também informações sobre a produtividade da plantação.

3.3 Experimentos . Adotamos uma abordagem multi-perspectiva inspirada na metodologia de experimentos descrita por QIU, Quan et al. (2019), com o objetivo de aumentar a densidade de pontos e compensar a oclusão parcial das plantas (10). Para isso, utilizamos placas de alumínio como pontos de referência (landmarks) alinhados paralelamente às plantações e à rota do robô. Essa configuração permite a identificação espacial da área estudada. O uso das landmarks




Fig. 6. Layout de coleta de dados

simplifica a integração das nuvens de pontos coletadas de diversos ângulos, resultando em um único mapa tridimensional unificado que abrange detalhes da vegetação observada sob diferentes perspectivas. Assim, com maior riqueza e resolução dos pontos, é possível uma segmentação e detecção das plantas, gerando informações mais precisas sobre sua estrutura. Os experimentos foram conduzidos na Embrapa Arroz e Feijão, localizada no município de Santo Antonio de Goiás, GO. Os dados foram coletados na safra 2023/2024 a partir de uma área total de 5 m x 5 m, formada por subparcelas distribuídas com diferentes genótipos de soja, que geram diferentes respostas de crescimento e produtividade em relação às mesmas condições do ambiente.

Durante a coleta de dados, mantemos uma distância de 2 metros do robô até as plantas, exceto nas duas últimas medições. O robô se desloca pela rota estipulada, efetuando paradas programadas de 30s nos pontos de coleta para a gravação das nuvens de pontos. Durante essas pausas, o LiDAR executa múltiplas varreduras a uma taxa de 5 Hz, gerando, em cada sessão, uma nuvem de 360 pontos que acumula mais de 1,33 milhão de pontos.

4 Pós-Processamento

Após a coleta das nuvens de pontos captadas pelo lidar é necessário a conversão dos arquivos “.bag” para o formato Point Cloud Data (PCD), que é nativamente suportado pelo software de processamento de nuvens de pontos 3D, Point Cloud Library (PCL). Arquivos bag são associados ao ROS (Robot Operating System) e são usados para registrar e armazenar dados do sensor, mensagens e estados durante a operação do robô. Para a reconstrução das point cloud coletadas, utilizamos o algoritmo LIO-SAM (Tightly-coupled Lidar Inertial Odometry via Smoothing and Mapping) (10), que se destaca pela capacidade de processar rapidamente grandes conjuntos de dados das point clouds, identificar elementos do ambiente e atualizar modelos 3D em tempo real. A eficiência no processamento desses dados é crucial inclusive para a navegação autônoma, usada em tempo real. O algoritmo é uma das implementações avançadas do LOAM (Lidar Lidar Odometry and Mapping in Real-time) (11). Fornecem mapeamento e localização simultâneos (SLAM) otimizado




Fig. 7. Point cloud gerada usando a reconstrução do algoritmo LIO-SAM.




Fig. 8. Point cloud gerada usando a reconstrução do algoritmo ALOAM.

para lidar com dados do sensor LiDAR e do IMU, tendo sido projetado para funcionar em tempo real oferecendo reconstrução e mapeamento 3D de alta precisão. O algoritmo usa dados do IMU para realizar o enquadramento da nuvem de pontos, permitindo que o tempo relativo do ponto em uma varredura seja conhecido. Da mesma família do LOAM, testamos também a reconstrução e mapeamento do ALOAM, que também realiza mapeamento 3D e localização simultâneos (SLAM), porém utiliza apenas os dados do LiDAR para realizar a odometria e mapeamento. Abaixo uma comparação entre os mapas gerados pelos algoritmos com os dados obtidos da 4ª coleta.

5 Percepção

5.1 Segmentação . A partir dos arquivos pcd 's gerados, foi possível aplicar o algoritmo RANSAC (Random Sample Consensus) (12) para a segmentação do chão. O método iterativo é um algoritmo robusto de ajuste de modelo que neste caso rejeita pontos discrepantes (outliers) que podem ser considerados observações incomuns rejeitadas. Após o processamento do algoritmo, o plano com o número máximo de inliers é a melhor estimativa do plano terrestre, então qualquer agrupamento de pontos deste plano terrestre pode ser classificado como objeto, ou no nosso caso, plantas.

5.2 Clusterização . Tendo um referencial do chão em relação ao resto da cena, foi possível realizar a clusterização do




Fig. 9. Segmentação do chão usando algoritmo RANSAC




Fig. 10. Utilização do algoritmo DBSCAN para clusterização do cenário

que sobrou após a segmentação do chão, utilizando o algoritmo DBSCAN (Density-Based Algorithm for Discovering Clusters in large spatial databases with noise) (13) para essa etapa do processo. Essa abordagem permitiu a identificação prévia de cada objeto na cena, essencial para os testes das hipóteses apresentadas na metodologia. A partir dessa identificação, calculamos a altura da estaca pela diferença do eixo Z entre o ponto mais próximo da base e o ponto máximo.

Os resultados, mesmo que para testes das hipóteses apresentadas na metodologia, foram animadores pois resultaram em uma taxa de erro médio de 4%, em comparação ao valor da altura real da estaca, medida de maneira manual para conferência dos experimentos. Este baixo percentual de erro reforça o potencial da combinação da segmentação por referencial de chão, clusterização via DBSCAN e análise detalhada dos pontos em 3D para o aprimoramento da precisão em aplicações de sensoriamento agrícola.

6 Aprendizado por Reforço - Controle de Caminhada

No contexto do projeto de robótica quadrúpede para sensoriamento em plantações de soja, a implementação de técnicas de Aprendizado por Reforço (RL) visa otimizar a estabilidade do lidar por meio do controle refinado da locomoção, com especial atenção à variação do eixo Z. Inspirados pelo conceito de Multiplicidade de Comportamento (MoB), conforme detalhado por Margolis e Agrawal (2022) (14), desenvolvemos uma política de controle que possibilita a experimentação com uma diversidade de comportamentos locomotivos. Esta estratégia é fundamental para alcançar uma coleta de dados precisa e confiável. O processo de otimização envolveu uma série de experimentações com diferentes configurações de valores na função de recompensa durante o treinamento de RL. Contrariamente à adaptação em tempo real desses parâmetros, realizamos um ajuste prévio e sistemático das recompensas para induzir a aprendizagem de padrões de caminhada que reduzem a oscilação vertical. Este método

iterativo de calibração das recompensas permitiu a identificação de conjuntos de valores que favorecem a estabilidade do eixo Z, mantendo a eficácia da locomoção sobre variados tipos de terreno. Atualmente, a equipe de RL encontra-se na fase de desenvolvimento e aprimoramento dessa política de controle. Estamos na etapa de realizar testes extensivos com os modelos treinados (checkpoints) no robô físico, para verificar a aplicabilidade e eficiência dos padrões de caminhada aprendidos no ambiente real das plantações. Essa fase de validação é crucial para assegurar que as estratégias de locomoção não apenas atendem aos critérios de estabilidade e precisão requeridos, mas também se adaptam de maneira efetiva às complexidades do terreno agrícola.

7 Próximos passos

Este projeto de robótica quadrúpede para sensoriamento em plantações de soja está em seus estágios iniciais de desenvolvimento. Atualmente, o foco reside na melhoria da densidade de pontos nas reconstruções 3D, que é crucial para obter informações precisas como a altura das plantas e a quantidade por metro linear. Estamos dedicados ao estudo e aos testes de processos para a sobreposição de diversas point clouds, buscando gerar um mapa único que oferece melhor resolução e qualidade das informações captadas. Paralelamente, a evolução dos algoritmos de navegação autônoma e a integração de sistemas de visão computacional são objetivos centrais, visando reconhecer e classificar as características fenotípicas das plantas. O uso de câmeras RGB e sensores espectrais será vital para analisar a saúde das plantas, seu crescimento e possíveis sinais de pragas ou doenças, fornecendo um conjunto de dados abrangente para análise genética e agrônômica. Nos próximos passos, pretendemos realizar estudos comparativos com o uso de drones para validar a eficácia e a eficiência dos robôs quadrúpedes em diferentes cenários de sensoriamento. Essas análises nos ajudarão a otimizar os recursos e as estratégias de coleta de dados. Além disso, a expansão das capacidades de aprendizado de máquina do projeto permitirá que o sistema se aperfeiçoe com o uso, adaptando-se às características específicas de cada lavoura e, assim, aumentando a precisão e a eficácia do sensoriamento.

Bibliography

- United Nations, Department of Economic and Social Affairs. Population estimates and projections section. Technical report, The United Nations, Population Division, 2012.
- Food and Agriculture Organization of the United Nations. *Anuário Estatístico da FAO 2013: Alimentação e Agricultura Mundial*. FAO, Rome, 2013.
- R. T. Furbank and M. Tester. Phenomics – technologies to relieve the phenotyping bottleneck. *Trends in Plant Science*, 16:635–644, 2011. doi: 10.1016/j.tplants.2011.09.005.
- Y. Lin. Lidar: An important tool for next-generation phenotyping technology of high potential for plant phenomics? *Computers and Electronics in Agriculture*, 119:61–73, 2015. doi: 10.1016/j.compag.2015.10.011.
- A. Singh, B. Ganapathysubramanian, A. K. Singh, and S. Sarkar. Machine learning for high-throughput stress plants. *Trends in Plant Science*, 21, 2016. doi: 10.1016/j.tplants.2015.10.015.
- A. Atefi, Y. Ge, S. Pitta, and J. Schnable. Robotic technologies for high-throughput plant phenotyping: Contemporary reviews and future perspectives. *Frontiers in Plant Science*, 12:611940, 2021. doi: 10.3389/fpls.2021.611940.
- Priyaranjan Biswal and Prases K. Mohanty. Development of quadruped walking robots: A review. *Ain Shams Engineering Journal*, 12(2):2017–2031, 2021.
- RobotLAB. Unitree go1 edu for researchers & developers. <https://www.robotlab.com/higher-ed-robots/store/unitree-go1-edu-researchers-developers>. Acesso em: 26 março 2024.
- W. R. Fehr, C. E. Caviness, and J. J. Vorst. Response of indeterminate and determinate soybean cultivars to defoliation and half-plant cut-off. *Crop Science*, 17(6):913–917, 1977.
- Quan Qiu et al. Field-based high-throughput phenotyping for maize plant using 3d lidar point cloud generated with a “phenomobile”. *Frontiers in Plant Science*, 10:427874, 2019.
- Ji Zhang and Sanjiv Singh. Loam: Lidar odometry and mapping in real-time. In *Robotics: Science and Systems*, pages 1–9, 2014.
- Martin A. Fischler and Robert C. Bolles. Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography. *Communications of the ACM*, 24(6):381–395, June 1981.
- Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD’96)*, pages 226–231. AAAI Press, 1996.
- Gabriel B. Margolis and Pulkit Agrawal. Walk these ways: Tuning robot control for generalization with multiplicity of behavior. In *Conference on Robot Learning*, pages 22–31. PMLR, 2023.